파이썬 데이터분석
전체 흐름 한 번에 잡기

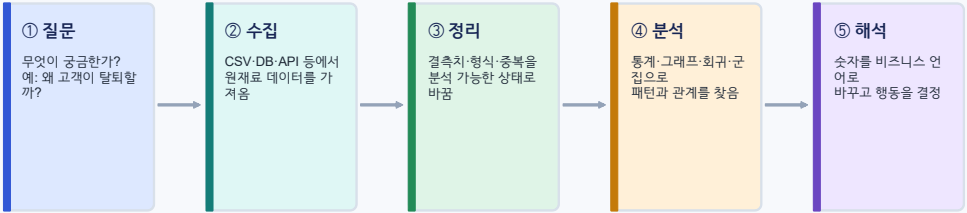
Pandas → 전처리 → 시각화·통계 → 회귀 → 군집 → 비즈니스 해석

Pandas　통계　회귀　K-Means

업로드한 실습 코드의 “왜 이 코드를 쓰는지”를 먼저 이해하는 개념 PPT

1. 데이터분석은 무엇을 하는가?

코드 암기보다 "질문 → 데이터 → 근거 → 판단" 흐름을 이해하는 것이 먼저



핵심: 데이터분석은 "그래프 그리기"가 아니라, 데이터를 근거로 질문에 답하는 과정이다.

2. 이번 코드에서 배우는 전체 지도

step1은 데이터 다루기·통계, step2는 모델링·고객분석으로 이어진다

1. Pandas
표 만들기·조회·변경

2. 전처리
결측치·형변환·선택

3. 집계/결합
groupby·agg·merge

4. 시각화/상관
그래프·corr·heatmap

5. 통계검정
t-test·p-value

6. 회귀
숫자 예측·영향 관계

7. 고객분석
로그 집계·회원기간

8. 군집
K-Means·엘보우

이 순서가 곧 실무 데이터분석 파이프라인의 축소판

3. Pandas와 DataFrame — 분석의 작업대

CSV를 읽으면 대부분 DataFrame이라는 "행 × 열 표"에서 작업한다

name	math	english
정약용	70	80
이순신	100	80
이율곡	90	95

행(row) = 한 건의 관측값
열(column) = 분석할 변수/특징

```
import pandas as pd

df = pd.read_csv('data/exam.csv')
df.head()
df.info()
df.describe()
```

수업 포인트

Pandas는 엑셀처럼 표를 다루지만, 코드를 남길 수 있어 반복·자동화·대용량 처리에 유리하다.

4. 조회·선택 — 필요한 데이터만 꺼내기

분석은 전체 데이터를 무작정 보는 것이 아니라 필요한 행과 열을 선택하는 작업의 반복

열 선택

df['math']
df[['math','english']]
→ 분석할 변수 선택

loc

df.loc[행이름, 열이름]
→ 이름(label) 기준 선택

iloc

df.iloc[행번호, 열번호]
→ 위치(index) 기준 선택

질문이 바뀌면 필요한 데이터도 바뀐다

원본 데이터 — 조건/열 선택 — 분석 대상

5. 전처리 — 현실 데이터는 바로 분석할 수 없다

결측치(NaN), 잘못된 형식, 불필요한 열을 정리해야 결과가 왜곡되지 않는다

결측치 확인

isnull().sum()
info()

삭제

dropna()
정보 손실 가능

대체

fillna(mean/median)
대표값으로 보완

앞/뒤 값

ffill() / bfill()
시계열에서 유용

결측치 처리에는 정답이 없다

왜 값이 비었는지, 데이터의 성격이 무엇인지 보고 방법을 선택해야 한다.

```
air.isnull().sum()
air['PM10'].fillna(air['PM10'].median())
df = df.drop(columns=['deck'])
```

6. groupby · agg · merge — 데이터를 요약하고 연결하기

실무 분석의 핵심은 “고객별·반별·월별로 묶고” 여러 표를 합치는 것

GROUPBY

같은 기준끼리 묶기
예: 반별, 성별, 회원권별

AGG

묶은 뒤 계산하기
평균·합계·중앙값·개수

MERGE

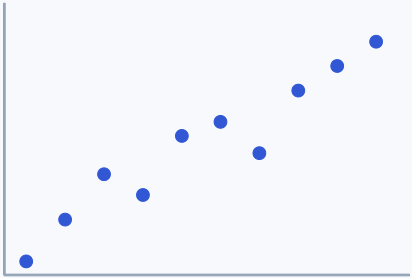
서로 다른 표 연결하기
고객 + 회원권 + 캠페인

```
exam.groupby('class').agg(
  mean_math=('math','mean'),
  count=('math','count'))
```

```
customer = customer.merge(class_master, on='class')
customer = customer.merge(campaign_master, on='campaign_id')
```

7. 기술통계와 시각화 — 데이터의 모양을 먼저 본다

모델을 만들기 전에 평균·분포·이상치·관계를 눈으로 확인해야 한다



산점도: 두 변수의 관계를 본다

describe()

평균(mean), 표준편차(std), 최소/최대, 사분위수

그래프

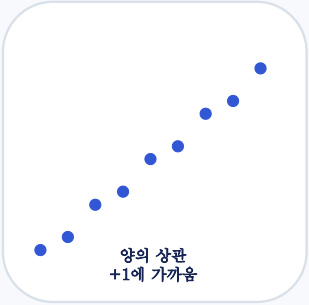
histplot · scatterplot · boxplot 등으로 분포와 이상치 확인

해석

"값이 크다"가 아니라 어떤 패턴이 있고 왜 그런지 설명

8. 상관관계 corr — 같이 움직이는 정도

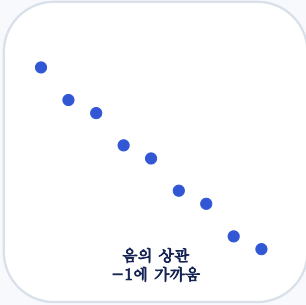
상관계수는 −1 ~ +1, 방향과 강도를 보지만, 원인·결과를 증명하지는 않는다



X가 증가할수록 Y도 증가
corr → +1



선형 상관관계가 거의 없음
선 형태로 같이 움직이는 관계가 거의 없다
corr → 0

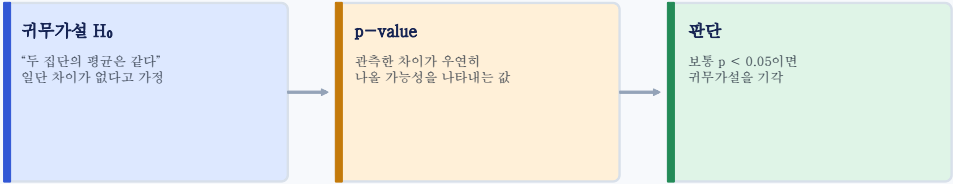


X가 증가할수록 Y는 감소
corr → −1

주의: 아이스크림 판매량과 익사 사고가 함께 증가해도 “아이스크림이 익사의 원인”은 아니다. 공통 원인인 여름 기온이 있을 수 있다.

9. t-test — 평균 차이가 우연인지 확인

그래프에서 차이가 보여도, 통계적으로 의미 있는 차이인지 검정하는 단계



예: p = 0.0108 < 0.05 → "두 그룹 평균은 같다"라는 가정을 기각

p-value는 "차이가 얼마나 큰가"가 아니라 "우연이라고 보기 어려운가"에 가깝다.

A반 평균점수 = 80점
B반 평균점수 = 70점

차이 = 10점
10점 차이가 진짜 실력 차이일까?
아니면 우연히 이번 시험에서만 이렇게 나온 걸까?

이걸 확인하는 것이 t-test이다

① 먼저 이렇게 생각한다
→ 귀무가설

처음에는 일단
"A반과 B반은 원래 실력이 비슷해."
라고 가정한다.

이것을 어려운말로 귀무가설(H_0)이라고 한다.

② 컴퓨터가 우연일 가능성을 계산한다 → p-value

컴퓨터에게 물어본다.
"두 반이 정말 비슷한데도
우연히 10점이나 차이가 날 수 있어?"

컴퓨터가 계산했더니 p-value = 0.01

우연히 이런 차이가 나올 가능성이
약 1% 수준으로 작다

③ 보통 0.05와 비교해서 판단

보통 $p < 0.05$이면
우연이라고 보기 어렵다고 판단
귀무가설을 기각

보통 통계에서는 5%(0.05)를
기준으로 많이 사용한다.

예: $p = 0.0108 < 0.05$ → "두 그룹 평균은 같다"라는 가정을 기각

$p < 0.05$ → 통계적으로 의미 있는 차이가 있다고 본다.
5% 기준을 유의수준(significance level, $\alpha=0.05$)이라고 부른다.
5%가 절대적인 법칙은 아니다. 연구 분야나 목적에 따라 0.01(1%), 0.10(10%) 등을 정해서 사용하기도 한다.

t-test와 p-value

t-test를 수행하면 p-value라는 값을 얻는다.

일반적으로 기준값인 0.05(5%)와 비교하여 판단한다.

① 통계학의 가설검정 방법이며 Python에서는 주로 SciPy를 사용한다.

```
from scipy.stats import ttest_ind
t_stat, p_value = ttest_ind(A반점수, B반점수)
print("p-value:", p_value)
```

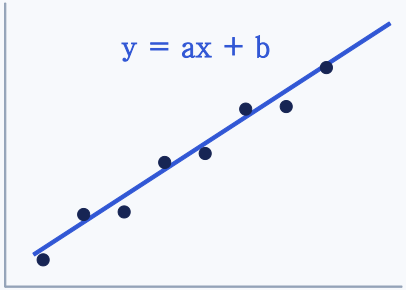
라이브러리	주요 역할
Pandas	데이터 불러오기, 정리, 전처리
NumPy	수치 계산
SciPy	통계 분석, t-test, 가설검정
scikit-learn	머신러닝, 회귀·분류·군집화
TensorFlow / Keras	딥러닝

$p \geq 0.05$ 값이 5% 가 넘으면 우연일 가능성이 있다.

5%는 통계적으로 차이가 있다고 인정할지 판단하는 기준선

10. 회귀분석 — 숫자를 예측하고 관계를 식으로 표현

단순회귀: 입력 1개 → 결과 1개 / 다중회귀: 여러 입력 → 결과 1개



예측

계란 무게 → 병아리 무게 / 자동차 특성 → 연비

계수(coef)

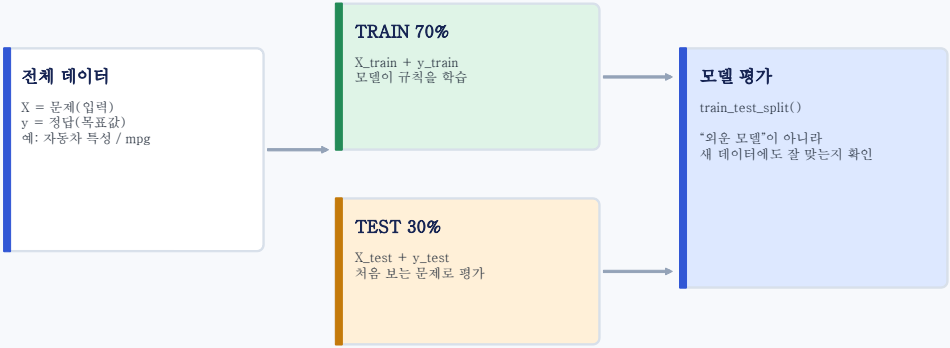
x가 1 증가할 때 y가 얼마나 변하는지

R^2 설명력

모델이 y의 변화를 얼마나 설명하는지 (0~1)

11. 머신러닝 관점 — 학습용과 시험용을 나누는 이유

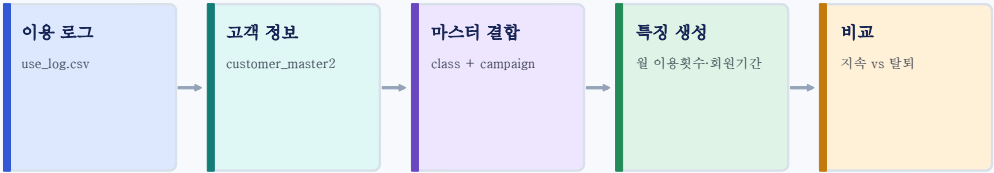
전체 데이터로 공부하고 같은 문제로 시험 보면 실제 실력을 알 수 없다



random_state = 같은 조건으로 다시 실험하기 위한 난수 고정값

12. 고객 로그 분석 — 분석 코드를 비즈니스 질문으로 연결

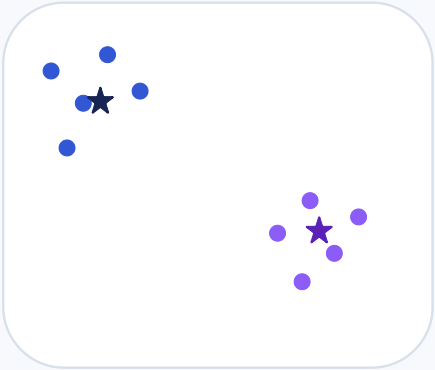
스포츠센터 예제는 여러 테이블을 합쳐 "누가 계속 오고 누가 떠나는가?"를 찾는 실전형 흐름



분석 결과의 목적: "고객별 특징"을 만들어 이후 군집화·이탈예측·마케팅으로 연결

13. K-Means 군집화 — 정답 없이 비슷한 고객끼리 묶기

비지도학습: y(정답)가 없고, 데이터의 거리와 패턴을 이용해 그룹을 찾는다



① 중심점 설정

K개의 중심점을 먼저 정한다.

② 가까운 중심에 배정

각 고객을 가장 가까운 그룹으로 보낸다.

③ 중심 재계산·반복

중심이 거의 움직이지 않을 때까지 반복한다.

중요: K-Means는 "그룹 번호"만 만든다. 그 그룹이 VIP인지 이탈위험군인지는 사람이 해석한다.

14. 표준화와 Elbow — 군집화 전에 꼭 이해할 것

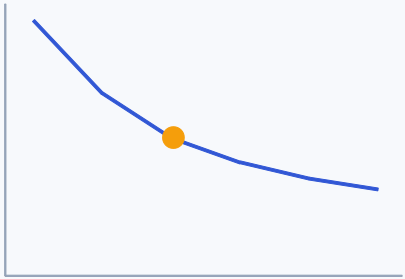
① 표준화 → ② Elbow → ③ K-Means 군집화 순서

단위가 다른 변수를 그대로 쓰면 큰 숫자를 가진 변수가 거리를 지배할 수 있다

표준화 StandardScaler

평균 0, 표준편차 1 기준으로 크기를 맞춤
예: 이용횟수(0~30)와 회원기간(0~1000일)을 같은 스케일로

```
sc = StandardScaler()
X_sc = sc.fit_transform(X)
```



Elbow: 꺾이는 지점 근처의 K를 후보로 선택

표준화(StandardScaler) 서로 단위와 크기가 다른 데이터를 비슷한 기준으로 맞추는 작업

StandardScaler를 적용하면 각 항목의 평균을 0, 표준편차를 1로 맞춘다.

예를 들어
키의 평균이 170cm라면

키	표준화 후 의미
160cm	− 평균보다 작음
170cm	0 평균 수준
180cm	+ 평균보다 큼

몸무게

몸무게	표준화 후 의미
50kg	− 평균보다 작음
60kg	0 평균 수준
70kg	+ 평균보다 큼

평균보다 작으면 − 값,
평균보다 크면 + 값,
평균과 같으면 0

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

data = [
    [160, 50],   # 키, 몸무게
    [170, 60],
    [180, 70]
]

scaled_data = scaler.fit_transform(data)

print(scaled_data)
```

```
[[-1.22, -1.22],
 [ 0.00,  0.00],
 [ 1.22,  1.22]]
```

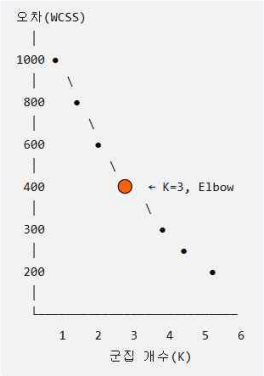
0~1 범위로 맞추는 것은 MinMaxScaler이고, StandardScaler는 평균을 0, 표준편차를 1로 맞추는 것

표준화와 Elbow — K-Means 군집화 준비

① 표준화 → ② Elbow → ③ K-Means 군집화

Elbow(팔꿈치)라는 이름은 그래프가 사람의 팔꿈치처럼 꺾이는 지점을 찾기 때문

키(cm) + 몸무게(kg)
↓
① StandardScaler
단위/크기를 맞춤
↓
② Elbow Method
몇 개의 그룹(K)으로 나눌지 결정
↓
③ K-Means
실제 군집화



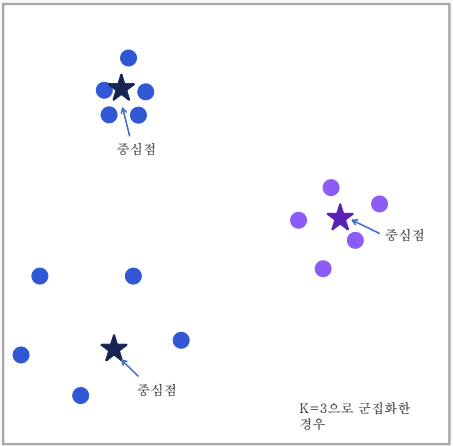
Elbow:
꺾이는 지점 근처의
K를 후보로 선택

```
K=1  오차 큼
K=2  오차 많이 감소
K=3  오차 많이 감소  ← ★ 팔꿈치
K=4  조금 감소
K=5  조금 감소
```

StandardScaler : 군집화 전에 데이터의 단위와 크기를 맞춘다.
Elbow Method : K-Means에서 몇 개의 군집(K)으로 나눌지 결정하는 방법이다.
그래프가 팔꿈치처럼 꺾이는 지점의 K를 후보로 선택한다.

Elbow Method(엘보우 기법) K-Means는 데이터를 보고 서로 가까운 것끼리 묶는다

K-Means에서 몇 개의 그룹으로 나눌지(K)를 정하는 방법 / K-Means는 데이터를 가까운 것끼리 묶고, 각 그룹의 중심점을 만든다.



군집내부거리(WCSS)란?

각 데이터가 자기 그룹의 중심점에서 얼마나 떨어져 있는지를 계산한 값이다.

WCSS = 같은 그룹 안의 데이터들이 중심점에서 떨어진 정도 (거리의 제곱합)

WCSS가 크다 → 같은 그룹인데 서로 많이 퍼져 있음
WCSS가 작다 → 같은 그룹끼리 중심점 주변에 잘 모여 있음

K를 증가 → WCSS가 계속 감소
감소 폭이 확 줄어드는 꺾이는 지점 → 적절한 K 후보

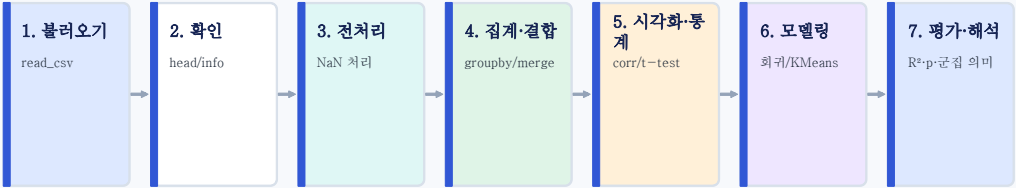
K를 늘렸는데 WCSS가 더 이상 크게 줄지 않는 꺾이는 지점을 찾는다.

Elbow Method = 그래프가 팔꿈치처럼 꺾이는 지점을 보고
적절한 군집 개수(K)를 결정하는 방법

K 증가 → WCSS 계속 감소 → 감소 폭이 확 줄어드는 지점 → 적절한 K 후보

15. 수업에서 학생이 잡아야 할 “한 장짜리” 전체 흐름

각 코드를 따로 외우지 말고, 어느 단계의 코드인지 위치를 찾게 한다



학생에게 계속 물을 질문 3개

① 지금 무엇을 하는 코드?

② 왜 이 단계가 필요한가?

③ 결과 숫자는 무슨 뜻인가?

이 세 질문에 답할 수 있으면 AI가 코드를 만들어줘도 학생이 코드를 통제할 수 있다.

16. 권장 수업 진행 순서

개념 → 짧은 코드 → 결과 해석 → 실전 데이터 순으로 반복하면 초보자 부담이 줄어든다

1차	**Pandas / DataFrame**	표를 코드로 다루는 감각
2차	**조회·전처리**	필요한 데이터 만들기
3차	**groupby / merge**	요약과 데이터 연결
4차	**시각화 / corr / t-test**	패턴과 통계적 근거
5차	**회귀**	예측과 영향 관계
6차	**고객 로그 분석**	실무형 데이터 가공
7차	**K-Means / Elbow**	비지도학습과 고객 세분화

마무리 과제: "스포츠센터 고객에게 어떤 행동을 제안할 것인가?"를 데이터 근거와 함께 3줄로 작성

데이터분석의 핵심

코드 → 숫자
숫자 → 의미
의미 → 판단

"무슨 함수를 썼는가?"보다 "왜 썼고 결과가 무엇을 뜻하는가?"를 설명할 수 있게 만드는 수업