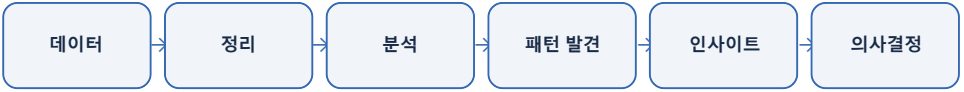
데이터 분석 핵심 개념

Pandas → 전처리 → 통계 → 회귀 → 머신러닝 → 군집화

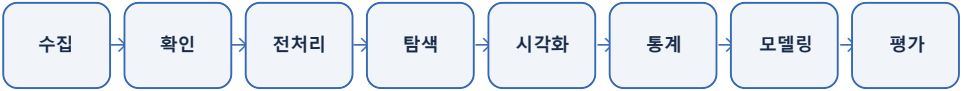
1. 데이터 분석이란?

데이터를 의미 있는 정보와 의사결정으로 바꾸는 과정



- 그래프를 그리는 것 자체가 목적은 아니다.
- 데이터에서 의미를 발견하고 실제 문제 해결에 활용하는 것이 핵심이다.

2. 데이터 분석 전체 흐름



- 수업 중에는 항상 '지금 어느 단계의 코드를 작성하고 있는가?'를 확인한다.
- 코드 암기보다 전체 분석 흐름을 이해하는 것이 먼저다.

3. Pandas와 DataFrame

Pandas

- Python의 대표적인 데이터 분석 라이브러리
- CSV·Excel·DB 데이터를 표 형태로 처리
- 필터링·집계·결측치 처리 등에 사용

DataFrame

- 행(Row)과 열(Column)로 이루어진 표
- 행 = 데이터 한 건
- 열 = 데이터의 특징(Feature)

4. 데이터를 받으면 먼저 확인한다

대표 함수

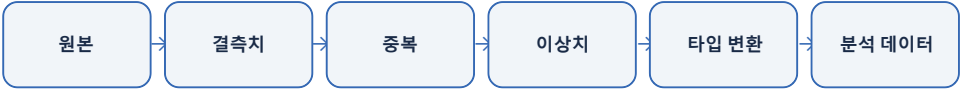
- head() : 앞부분 확인
- tail() : 뒷부분 확인
- info() : 컬럼·타입·결측치 확인
- describe() : 기초 통계량 확인

왜 확인할까?

- 컬럼의 의미를 파악
- 숫자/문자 데이터 타입 확인
- 결측치나 이상한 값 발견
- 분석 방향을 결정

5. 데이터 전처리

분석하기 좋은 상태로 데이터를 정리하는 과정



- 결측치(Missing Value) = 값이 없는 데이터, 주로 NaN으로 표시
- 이상치(Outlier) = 다른 값들과 지나치게 차이나는 데이터
- 이상치는 무조건 삭제하지 말고 발생 이유부터 확인한다.

6. 데이터를 요약하는 대표 통계값

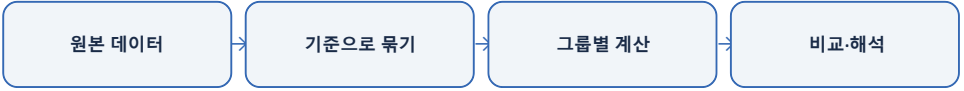
대표값

- 평균(Mean) : 전체의 평균적인 수준
- 중앙값(Median) : 정렬했을 때 가운데 값
- 최빈값(Mode) : 가장 자주 등장하는 값

퍼짐 정도

- 분산(Variance) : 평균에서 얼마나 퍼졌는지
- 표준편차(Standard Deviation) : 퍼짐 정도를 해석하기 쉽게 표현
- 평균만 같아도 분포는 전혀 다를 수 있다

7. GroupBy와 집계



- groupby() = 같은 종류의 데이터를 그룹으로 묶는다.
- agg() = mean, sum, count, max, min 등 여러 집계값을 계산한다.
- SQL의 GROUP BY와 같은 개념으로 연결하면 이해하기 쉽다.

8. 데이터 시각화

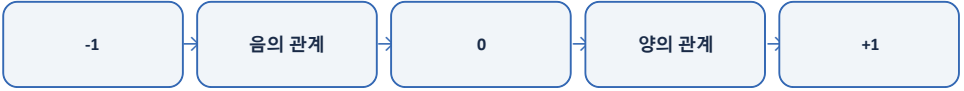
대표 그래프

- 막대그래프 : 그룹 비교
- 선그래프 : 시간에 따른 변화
- 산점도 : 두 변수의 관계
- 히스토그램 : 데이터 분포
- Box Plot : 분포와 이상치

핵심

- 숫자만 볼 때 놓치는 패턴을 발견
- 그래프 종류는 분석 목적에 맞게 선택
- 예쁜 그래프보다 올바른 해석이 중요

9. 상관관계(Correlation)



- 상관계수는 두 변수가 함께 움직이는 정도를 나타낸다.
- +에 가까우면 같은 방향, -에 가까우면 반대 방향으로 움직이는 경향이 강하다.
- 중요: 상관관계가 있다고 해서 원인과 결과라는 뜻은 아니다. 상관관계 ≠ 인과관계

10. t-test와 p-value

두 그룹의 평균 차이가 우연인지 판단

가설

- 귀무가설(H_0) : 두 그룹에 차이가 없다
- 대립가설(H_1) : 두 그룹에 차이가 있다

p-value

- 흔히 $p < 0.05$이면 귀무가설을 기각
- '우연이라고 보기 어렵다'고 판단
- 0.05는 자주 사용하는 기준이며 절대 법칙은 아니다

11. 독립변수(X)와 종속변수(y)



- X = 결과를 설명하거나 예측하는 데 사용하는 입력 특징
- y = 우리가 설명하거나 예측하려는 결과
- 예: 달걀 무게(X) → 병아리 무게(y)

12. 회귀분석(Regression)

단순 선형회귀

- 독립변수 x가 1개
- y = ax + b
- 예: 달걀 무게 → 병아리 무게

다중 선형회귀

- 독립변수 x가 여러 개
- 여러 요인이 하나의 결과에 영향을 줌
- 예: 무게·배기량·연식 → 자동차 연비

13. 모델의 학습과 예측



- fit() = 데이터를 보고 규칙을 찾는 과정 → '공부시키기'
- predict() = 학습한 규칙을 새로운 데이터에 적용 → '시험 보기'

14. Train / Test와 과적합

데이터 분리

- Train : 모델이 학습하는 데이터
- Test : 학습하지 않은 데이터로 성능 평가
- 새로운 데이터에서도 잘 작동하는지 확인

과적합(Overfitting)

- 학습 데이터를 너무 잘 외운 상태
- Train 성능은 높지만 Test 성능이 낮을 수 있음
- 좋은 모델 = 처음 보는 데이터에서도 잘 작동

15. 회귀 모델 평가

R^2 결정계수

- 모델이 종속변수의 변동을 얼마나 설명하는지 나타내는 지표
- 일반적으로 높을수록 설명력이 큼
- 높다고 무조건 좋은 모델은 아님

MSE

- 실제값과 예측값의 차이를 제곱해 평균
- 일반적으로 작을수록 예측 오차가 작음
- 모델 간 예측 성능 비교에 사용

16. 머신러닝의 큰 분류

지도학습

- 정답(Target)이 있는 데이터로 학습
- 회귀 : 숫자 예측
- 분류 : 종류·범주 예측

비지도학습

- 정답이 없는 데이터에서 패턴 탐색
- 대표 예: 군집화(Clustering)
- 비슷한 고객·상품·행동을 그룹화

17. K-Means 군집화



- K-Means = 비슷한 특징을 가진 데이터를 K개의 그룹으로 나누는 대표 군집 알고리즘
- 예: 충성 고객 / 신규 고객 / 이용 감소 고객 / 이탈 위험 고객
- 정답을 맞히는 것이 아니라 만들어진 그룹의 의미를 사람이 해석해야 한다.

18. 표준화(Standardization)

왜 필요할까?

- 나이: 20~70
- 연봉: 3,000~10,000
- 방문횟수: 1~30
- 숫자 크기가 큰 변수가 거리 계산을 지배할 수 있음

StandardScaler

- 각 변수의 척도를 공통 기준으로 맞춤
- 거리 기반 알고리즘에서 특히 중요
- K-Means 전에 자주 사용

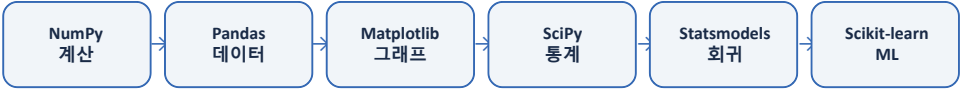
19. Elbow Method

K-Means에서 적절한 K의 후보를 찾는 방법



- K를 늘리면서 군집 내부 오차가 얼마나 줄어드는지 확인한다.
- 오차 감소 폭이 급격히 둔화되는 '팔꿈치' 지점을 K의 후보로 본다.
- Elbow 결과만 맹신하지 말고 실제 비즈니스 해석도 함께 고려한다.

20. 데이터 분석 라이브러리 지도



- 라이브러리를 외우기보다 '어떤 역할을 담당하는 도구인가?'를 먼저 이해한다.

21. 핵심 용어 한눈에 보기

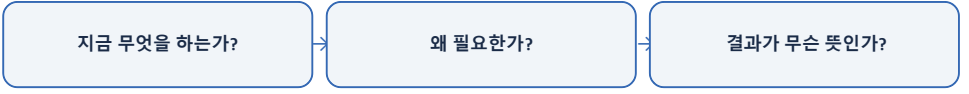
데이터 처리

- DataFrame = 표
- Feature = 입력 특징
- Target = 예측 대상
- 전처리 = 데이터 정리
- GroupBy = 같은 기준끼리 묶기

분석·모델링

- Correlation = 함께 움직이는 정도
- Regression = 숫자 관계 설명·예측
- fit = 학습
- predict = 예측
- Clustering = 비슷한 데이터끼리 묶기

22. 수업에서 가장 중요한 질문



- 함수 이름을 외우는 것보다 이 세 질문에 답할 수 있어야 한다.
- 데이터 분석의 최종 목적은 코드 실행이 아니라 '의미 있는 해석과 의사결정'이다.